

# Diagnóstico de enfermedades respiratorias en radiografías de tórax utilizando concatenación de redes neuronales convolucionales.

Christian Garrido, Cristobal Cortés, Rodrigo Pino, Agustín Schmauck, Vicente Córdova

Institución

Correo Electrónico: c.garridomeneses@uandresbello.edu, c.cortsgamboa@uandresbello.edu, r.pinomeneses@uandresbello.edu, a.schmauckmedina@uandresbello.edu, v.crdovacastillo@uandresbello.edu

**Abstract**—En este artículo de investigación, se propone un modelo de clasificación multiclase que pueda cubrir un amplio rango de enfermedades pulmonares, aprendiendo a detectar un total de cuatro clases, desde tres enfermedades pulmonares tales como Covid-19, Neumonía y Tuberculosis a pulmones normales que están sanos, el cual sería la etiqueta negativa. Todo esto utilizando la concatenación de mapas de características de modelos preentrenados y un conjunto de datos de imágenes de radiografías de tórax.

Este estudio abarca desde una revisión exhaustiva de la literatura, que resalta la eficacia de los modelos preentrenados en aplicaciones médicas, hasta los detalles de la metodología implementada.

## I. INTRODUCCIÓN

En los últimos diez años, la inteligencia artificial ha progresado considerablemente, especialmente en el área del diagnóstico médico asistido por computadora. Las redes neuronales convolucionales (CNNs) han mostrado un rendimiento excepcional en la interpretación de imágenes médicas, como las radiografías de tórax [1] [2] [3], permitiendo la detección precisa de diversas enfermedades. No obstante, queremos explorar en esta investigación cómo la combinación de múltiples modelos puede potenciar aún más estos resultados, o también podría no hacerlo.

La concatenación de modelos de redes neuronales convolucionales para mejorar la detección de enfermedades en radiografías de tórax representa un avance crucial en la aplicación de la inteligencia artificial en el diagnóstico médico, con el potencial de transformar la atención sanitaria y salvar vidas. Así mismo, entregando diferentes enfoques convencionales de aprendizaje por conjuntos para generar la clasificación de salida final. [4]

La concatenación de modelos implica combinar dos o más redes neuronales para trabajar en conjunto, con el propósito de aumentar la precisión y la robustez del diagnóstico. Esta técnica puede aprovechar las fortalezas de distintos modelos individuales y mitigar sus debilidades. Este estudio se centra en evaluar si la concatenación de dos o más modelos de CNN puede mejorar la identificación de patologías torácicas en comparación con el desempeño de cada modelo individual. Utilizando un conjunto de datos amplio y variado de radiografías

de tórax con tres tipos de enfermedades distintas, se realizarán experimentos para comparar los resultados de modelos individuales frente a modelos concatenados en términos de precisión, sensibilidad, especificidad y otras métricas relevantes.

En el campo de la investigación de radiografías de tórax mediante inteligencia artificial, se ha dependido en gran medida de grandes volúmenes de datos para entrenar los modelos. Afortunadamente, en los últimos años se han hecho públicas varias bases de datos extensas y etiquetadas, gracias principalmente a la capacidad de generar etiquetas automáticamente a partir de los informes de los radiólogos, sin necesidad de etiquetar las imágenes manualmente.

Los hallazgos de esta investigación proporcionarán información sobre la viabilidad y eficacia de la concatenación de modelos en el diagnóstico por imagen, y podrían influir en futuras aplicaciones y desarrollos de herramientas de diagnóstico asistido por inteligencia artificial. En última instancia, la mejora en la detección temprana y precisa de enfermedades a través de radiografías de tórax puede tener un impacto significativo en la atención médica, potencialmente salvando vidas y optimizando recursos en el sistema de salud.

## II. ESTADO DEL ARTE

Ibrahim et al. [5], desarrolla un modelo de aprendizaje profundo para clasificar neumonía a partir de radiografías de tórax, El modelo estaba basado en la arquitectura de AlexNet para entregar una salida con múltiples categorías de enfermedades pulmonares tales como Neumonía bacteriana, COVID-19, Neumonía viral y Normal. Consiguiendo unas métricas de Exactitud, sensibilidad y especificidad de COVID-19, Neumonía viral, Neumonía bacteriana, y Normal de aproximadamente 93.42%, 89.18%, y 98.92%, respectivamente.

Ashraf et al. [6] utiliza seis modelos diferentes para la clasificación de 14 tipos de condiciones pulmonares en radiografías de tórax. Estos modelos se dividen en tres tipos de arquitecturas principales: Redes Neuronales Convolucionales (CNN), Transformers Visuales (ViT), y arquitecturas híbridas que combinan CNN y ViT. En el grupo de las redes neuronales convolucionales, se emplearon DenseNet y ConvNeXt V2, conocidos por su capacidad para extraer características

detalladas de las imágenes médicas y mejorar la precisión del diagnóstico a través de convoluciones profundas y eficientes.

Para los Transformers Visuales, el estudio utilizó Swin Transformer V2 y Vision Outlooker (VOLO). Estos modelos son particularmente efectivos para capturar relaciones espaciales complejas en las imágenes debido a su mecanismo de autoatención, que permite procesar información de diferentes partes de la imagen en paralelo. Esta característica es crucial para identificar patrones sutiles en las radiografías que pueden indicar diversas patologías pulmonares.

Finalmente, las arquitecturas híbridas incluyeron CoAtNets y MaxViT, las cuales combinan las ventajas de las CNN y los ViT. CoAtNets integran convoluciones con mecanismos de atención, permitiendo una mejor extracción y procesamiento de características tanto locales como globales. MaxViT, por otro lado, combina la eficiencia de las CNN con la capacidad de autoatención de los transformers, logrando un equilibrio entre precisión y rendimiento computacional.

Además de la combinación de estos modelos, el estudio implementó técnicas avanzadas de preprocesamiento de datos, como el redimensionamiento y la normalización de imágenes, así como aumentos de datos mediante volteos horizontales y rotaciones aleatorias. El conjunto de datos se dividió cuidadosamente en grupos de entrenamiento, validación y prueba, asegurando que no hubiera solapamientos entre los pacientes en estos grupos.

El proceso de entrenamiento incluyó el uso de la técnica de tasa de aprendizaje cíclica y el optimizador AdamW, lo que ayudó a encontrar la tasa de aprendizaje óptima para cada modelo. La combinación de los modelos se realizó mediante técnicas de ensamblaje, como el apilamiento y el promedio ponderado, utilizando evolución diferencial para determinar los pesos óptimos de cada modelo. Esto resultó en una mejora significativa en el rendimiento, alcanzando un AUROC promedio del 85.4% lo que supera a otros métodos de última generación en esta tarea.

Saha et al. [7] proponen un modelo que utiliza cuatro CNN con distintas arquitecturas de capas convolucionales como extractores de características. La capa de concatenación se conectó a una capa de 32 neuronas con activación ReLU, seguida de un clasificador. Los extractores de características incluyen dos capas convolucionales (tamaño de filtro 3x3), una capa de normalización por lotes, una capa de maxpooling (tamaño de agrupamiento 2x2) y una tasa de abandono del 0.5.

Los resultados demuestran la eficiencia y robustez del modelo, con una exactitud promedio del 96.31%, precisión promedio del 95.8%, recall promedio del 92.99% y AUC promedio del 98.02%. Estos resultados superan a modelos de última generación como VGG16, InceptionV3, Resnet50 y DenseNet121, mostrando la capacidad superior del modelo Concat\_CNN para detectar COVID-19, neumonía y estado de salud normal en radiografías de tórax.

Alexander et al. [8] utiliza un enfoque novedoso en el campo de la visión por computadora mediante la introducción de las Redes de Kolmogorov-Arnold Convolucionales (Convolutional

Kolmogorov-Arnold Networks, KAN). Estas redes proponen una adaptación de la idea de aprendizaje de splines a las capas convolucionales utilizadas en redes neuronales convolucionales (CNNs).

El estudio compara el rendimiento de las Convolutional KANs con las redes neuronales convolucionales tradicionales en los conjuntos de datos MNIST y Fashion MNIST. Se analizan métricas como precisión, recall, puntaje F1, cantidad de parámetros y tiempo de entrenamiento por época para evaluar el desempeño de los diferentes modelos propuestos.

En el conjunto de datos MNIST, las Convolutional KANs logran mantener altos niveles de precisión: 98.90% de accuracy, 98.90% de precision, 98.89% de recall y 98.90% en F1 score, con 94,875 parámetros, significativamente menos que las CNNs convencionales, que tienen 157,000 parámetros y obtienen 99.12% de accuracy, 99.12% de precision, 99.12% de recall y 99.12% en F1 score.

En el conjunto de datos Fashion MNIST, las Convolutional KANs obtienen 89.69% de accuracy, 89.62% de precisión, 89.69% de recall y 89.62% en F1 score, también con 94,875 parámetros. En comparación, las CNNs tradicionales logran 90.14% de accuracy, 90.13% de precisión, 90.14% de recall y 90.13% en F1 score con 157,000 parámetros entrenables.

Estos resultados demuestran que las Convolutional KANs tienen la capacidad de optimizar modelos de deep learning, obteniendo resultados comparables a los ya existentes, pero con una significativa reducción en la cantidad de parámetros necesarios.

### III. MATERIALES Y MÉTODOS

#### A. Definición del estudio

Este estudio busca mejorar la clasificación de enfermedades como Covid-19, Neumonía y Tuberculosis en radiografías de tórax mediante la concatenación de los mapas de características. Primero se entrenarán 3 modelos pre-entrenados con el dataset de radiografías de tórax. Los 2 modelos con mejores métricas entre VGG16, Xception y DenseNet121 se utilizarán para crear un último modelo con la concatenación de sus mapas de características. Esta estrategia permite aprovechar las fortalezas de los diferentes modelos y mitigar sus debilidades. Se utilizarán los mapas de características concatenados junto a capas densas para obtener una clasificación final que logre superar a los modelos existentes. La evaluación del rendimiento se llevará a cabo utilizando métricas para modelos de clasificación tales como la exactitud, sensibilidad, especificidad, recall, f1-score y la pérdida a lo largo del entrenamiento, así como la generación de una matriz de confusión para evaluar la calidad del modelo en esta tarea de clasificación.

La metodología se detalla a continuación para permitir que otros investigadores puedan replicar el estudio:

**Recolección de datos:** Se utilizará un conjunto combinado de tres conjuntos de datos de radiografías de tórax que incluye imágenes etiquetadas con diagnósticos de Covid-19, Neumonía y Tuberculosis. Los datos se obtendrán de

páginas públicas para poder ser separadas en conjuntos de entrenamiento, validación y prueba.




Fig. 1. Muestreo de los datos

**Preparación de los datos:** Antes de poder entrenar, es necesario que las imágenes usen el mismo formato, ya que se está combinando tres conjuntos de datos que no tienen las mismas características. Algunas de las acciones que vamos a realizar son las siguientes:

- Redimensionamiento de imágenes: Todas las imágenes serán redimensionadas a un tamaño de  $224 \times 224$  en RGB para garantizar su compatibilidad con los modelos.
- Normalización: Ajustar los valores de los píxeles para poder lograr que el modelo entrene de manera eficiente y manejable para el modelo.

### B. Configuración experimental

El entorno en el que se trabajó es el que otorga la plataforma de Google Colab, el cual cuenta con una tarjeta gráfica Nvidia Tesla T4 de 16 GB, un procesador Intel Xeon a 2,20 GHz, 13 GB de RAM y 78 GB de espacio.

### C. Descripción de la actividad

Para llevar a cabo este estudio, se procederá con la inicialización de modelos pre-entrenados, específicamente las arquitecturas VGG16, Xception y DenseNet121, las cuales han sido previamente entrenadas en el conjunto de datos ImageNet. Una vez inicializados los modelos, se procederá a la construcción de estos modelos con capas densas y entrenarlos para evaluar su rendimiento en este dataset. Los 3 Modelos compartirán la misma arquitectura de capas densas la cual consiste en 3 capas ocultas con 1024, 512 y 256 neuronas, cada capa seguida de un Dropout de 0.3 y función de activación 'ReLU', para la salida de la red como se tienen 4 clases se utilizan

4 neuronas con función de activación 'SoftMax'. Posteriormente, se visualizarán sus métricas para evaluar el rendimiento individual de cada modelo por separado y se escogerán los 2 mejores basados en su 'Val\_accuracy' y 'Val\_loss'. En este caso, los 2 modelos con mejor rendimiento fueron Xception y DenseNet121 con un 'Val\_accuracy' y 'Val\_loss' de 92.11%, 0.345 y 89.47%, 0.193, respectivamente.

Posteriormente, se creará un último modelo que utilice los 2 anteriores para la extracción de los mapas de características. Esta concatenación se realizará mediante operaciones de concatenación de tensores, lo cual permitirá combinar la información capturada por cada una de las arquitecturas. Una vez obtenida la representación concatenada, esta se propagará a través capas densas que siguen la misma arquitectura que los modelos hechos anteriormente.

La arquitectura de las capas densas se ajustará para aprender las representaciones más relevantes de los mapas de características concatenados. Se establecerán tamaños adecuados de unidades y conexiones entre las capas para optimizar el aprendizaje. Finalmente, la salida de la última capa completamente conectada se procesará mediante una capa de salida con una activación 'SoftMax', lo que permitirá generar la clasificación final de las clases de interés.

Una vez construido y compilado el modelo, se procederá con el entrenamiento utilizando un conjunto de datos previamente dividido en conjuntos de entrenamiento, validación y prueba en una proporción adecuada. Durante el entrenamiento, se optimizará la función de pérdida utilizando el optimizador Adam con una tasa de aprendizaje de  $1e-3$ , junto a una función de pérdida de 'Categorical\_crossentropy' la cual es adecuada para este tipo de tarea de clasificación multiclase. Posteriormente, se evaluará el desempeño del modelo utilizando el conjunto de prueba. Se calcularán y analizarán métricas de evaluación previamente definidas, tales como precisión, recall, f1-score para cada clase, además de otras métricas que evalúan el rendimiento general del modelo, tales como Micro Average, Macro Average y Weighted Average. Este proceso garantizará una evaluación exhaustiva del modelo y su capacidad para generalizar a datos no vistos.

## IV. EXPERIMENTOS

En los experimentos realizados, evaluamos el rendimiento de tres arquitecturas de redes neuronales convolucionales (CNNs) preentrenadas: Xception, VGG16 y DenseNet. Estas arquitecturas fueron seleccionadas por su alto rendimiento en diversas tareas de clasificación de imágenes.

### A. Configuración de los Modelos

Cada modelo fue configurado con las siguientes capas adicionales para la extracción de características:

- Una capa Densa con 1024 neuronas con activación 'ReLU', seguido de Dropout con tasa de 0.3.
- Otra capa Densa con 512 neuronas con activación 'ReLU', seguido de Dropout con tasa de 0.3.
- Otra capa Densa con 256 neuronas con activación 'ReLU', seguido de Dropout con tasa de 0.3.
- Capa final con 4 neuronas para la clasificación de las clases objetivo con activación 'SoftMax'.

### B. Proceso de Entrenamiento y Evaluación

Para cada modelo, se utilizó una entrada de dimensiones  $224 \times 224 \times 3$ , correspondiente a la resolución y el número de canales de las imágenes de entrada. Cada modelo se entrenó individualmente utilizando el conjunto de datos.

Los resultados del proceso de entrenamiento, que se pueden ver en las figuras 4 y 5, demostraron que los modelos Xception y DenseNet presentaron un desempeño superior en comparación con el modelo vgg16 evaluado. Estos dos modelos se destacaron por su alta precisión y robustez en la clasificación de imágenes. Con base en estos hallazgos, se decidió avanzar a la siguiente fase del experimento, utilizando las características extraídas de ambos modelos para realizar la concatenación y evaluar su rendimiento combinado en la tarea de clasificación.

### C. Concatenación de Modelos

Dado que Xception y DenseNet mostraron ser los modelos más prometedores durante la evaluación individual, se decidió concatenar las características extraídas de ambos modelos. El proceso de concatenación fue el siguiente:

- 1) **Extracción de Características:** Se obtuvieron las características de los modelos Xception y DenseNet.
- 2) **Flattening:** Las características de ambos modelos se aplanaron.
- 3) **Concatenación:** Las características aplanadas de ambos modelos se concatenaron para formar una sola representación combinada.
- 4) **Capas Adicionales:** La representación combinada se pasó a través de las capas adicionales mencionadas anteriormente (1024, dropout 0.3, 512, dropout 0.3, 256, dropout 0.3 y finalmente 4 neuronas).

Esta concatenación permitió aprovechar las fortalezas de ambos modelos, mejorando así el rendimiento de la clasificación en comparación con el uso de un solo modelo.

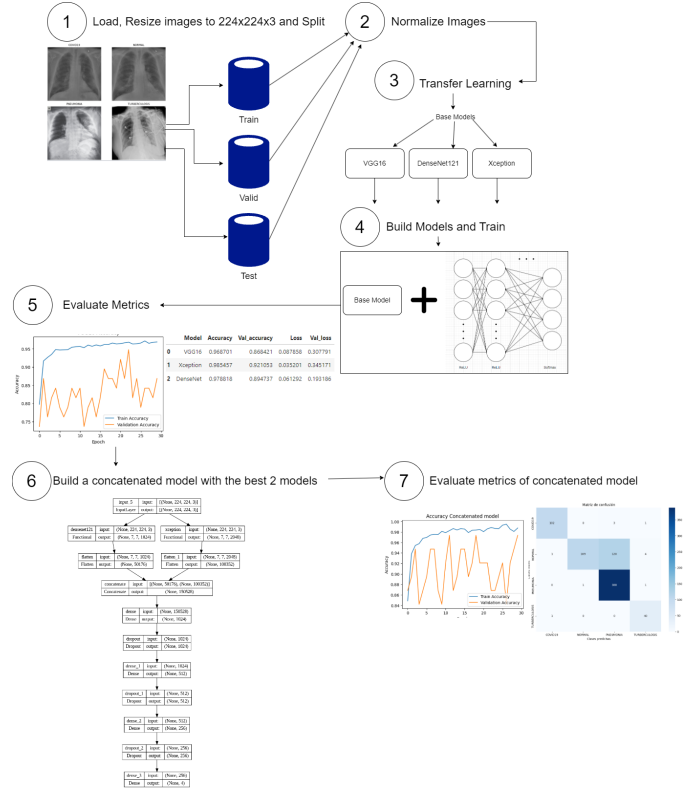


Fig. 2. Diagrama de solución propuesta

## V. ANÁLISIS DE RESULTADOS

### A. Gráficos de entrenamiento




Fig. 3. Métricas modelo VGG16




Fig. 4. Métricas modelo DenseNet




Fig. 5. Métricas modelo Xception

	Precisión	Recall	F-Score
Covid-19	0.99	0.94	0.96
Normal	0.60	0.96	0.74
Pneumonia	0.98	0.82	0.90
Tuberculosis	1.00	0.91	0.95
Micro Average	0.87	0.87	0.87
Macro Average	0.89	0.91	0.89
Weighted Average	0.87	0.88	0.86

TABLE III  
MÉTRICAS CONCATENADO

### C. Curvas ROC




Fig. 6. Métricas modelo Concatenado




Fig. 7. Métricas modelo Concatenado

### B. Métricas

	Precisión	Recall	F-Score
Covid-19	0.92	1.00	0.96
Normal	0.55	0.93	0.69
Pneumonia	0.98	0.78	0.87
Tuberculosis	1.00	0.82	0.90
Micro Average	0.84	0.84	0.84
Macro Average	0.86	0.88	0.85
Weighted Average	0.84	0.86	0.83

TABLE I  
MÉTRICAS XCEPTION

	Precisión	Recall	F-Score
Covid-19	0.92	0.95	0.93
Normal	0.43	0.97	0.59
Pneumonia	0.99	0.74	0.85
Tuberculosis	0.98	0.87	0.92
Micro Average	0.81	0.81	0.81
Macro Average	0.83	0.88	0.82
Weighted Average	0.81	0.85	0.79

TABLE II  
MÉTRICAS DENSENET




Fig. 8. Métricas modelo Concatenado




Fig. 9. Métricas modelo Concatenado

#### D. Modelo concatenado

Los resultados obtenidos por el modelo concatenado se presentan en la Tabla 6, que muestra las métricas detalladas del conjunto de entrenamiento y validación durante el proceso de entrenamiento.

Estas métricas se compararon con las de los modelos previamente entrenados sin concatenar, cuyos resultados se encuentran en las Tablas 3, 4 y 5. En particular, se analizaron parámetros como la precisión, la pérdida respecto al entrenamiento y las validaciones.

La comparación entre los modelos indica que las métricas del modelo concatenado son ligeramente superiores a las de los modelos Xception y DenseNet en términos de rendimiento durante el entrenamiento. Este hallazgo sugiere una mejora en la capacidad del modelo concatenado para extraer características del dataset.

Es importante destacar que, aunque estos resultados preliminares son prometedores, será fundamental evaluar el rendimiento del modelo con el conjunto de datos de pruebas. Esta evaluación adicional permitirá confirmar si las mejoras observadas en el entrenamiento se traducen en un mejor rendimiento general del modelo. No obstante, estos resultados iniciales representan un buen comienzo en el desarrollo de un modelo más eficaz y robusto.

Una vez que el modelo fue probado en el set de pruebas, se generaron las tablas que proporcionan los resultados de precisión, Recall y F-score del modelo multiclase. Estas tablas permiten comparar el rendimiento de los modelos Xception y DenseNet antes de concatenar, así como el rendimiento del modelo concatenado entre estos.

En la tabla III, se observa que el modelo concatenado exhibe métricas notablemente superiores o muy cercanas a las mejores métricas individuales de otros modelos, en comparación con las tablas de referencia I y II. Específicamente, el modelo concatenado muestra una alta precisión y mejora el recall en

la mayoría de los casos. La única excepción se encuentra en la métrica de "Pneumonia", donde se observa una ligera disminución de la precisión en 0.01 en comparación con el modelo DenseNet, aunque el recall aumentó en 0.08 puntos, lo cual contribuye a la estabilidad general del modelo.

Además, al analizar las métricas de Micro Average, Macro Average y Weighted Average, se observa una mejora significativa en el modelo concatenado. Estos promedios, aunque reflejan un equilibrio entre todos los modelos evaluados, muestran un rendimiento superior en comparación con los modelos individuales.

Las curvas ROC también destacan el desempeño del modelo concatenado (Figura 9), demostrando métricas casi perfectas en comparación con el modelo DenseNet (Figura 8), que previamente mostraba el mejor desempeño. Específicamente, se observa una mejora de 0.01 en la métrica de la clase normal, lo cual subraya la robustez y precisión adicionales alcanzadas por el modelo concatenado en la tarea de clasificación.

## VI. CONCLUSIONES

En el presente experimento, hemos desarrollado un modelo de predicción multiclase que supera significativamente a los modelos individuales probados previamente. La combinación de las características de los modelos Xception y DenseNet ha dado lugar a un modelo concatenado que demuestra un rendimiento superior en la detección de Neumonía, Covid-19 y Tuberculosis.

El modelo concatenado se destaca por su excelente precisión y recall en la identificación de casos positivos, reduciendo considerablemente los falsos negativos y falsos positivos en comparación con los modelos individuales. Los resultados obtenidos muestran un Micro Average de 0.87 en precisión y recall, un Macro Average con precisión de 0.89 y recall de 0.91, y un Weighted Average de 0.87 en precisión y 0.88 en recall, lo que refleja un rendimiento general robusto y equilibrado.

La mejora en precisión y recall indica que el modelo concatenado no solo es más confiable y eficiente en sus predicciones generales, sino que también maneja mejor las variaciones entre las diferentes clases de enfermedades. Este equilibrio es crucial para aplicaciones prácticas en el mundo real, donde es fundamental mantener un rendimiento uniforme en todas las clases.

## VII. TRABAJOS FUTUROS

Aunque este trabajo ha demostrado eficacia en la clasificación de enfermedades pulmonares, aún existen diferentes métodos o aspectos a mejorar en trabajos futuros. Primero, se podría considerar optimizar parámetros con Keras Tuner para encontrar los mejores hiperparámetros para los modelos a utilizar. También se debe tener en cuenta el balanceo de datos, ya que esto podría afectar la detección de una clase respecto a otra. Además, sería beneficioso explorar y concatenar los feature maps de otros modelos como InceptionV3 o EfficientNetB0-B7 por mencionar algunos.

Otro trabajo futuro sería implementar las redes Kan-Kolmogorov, arquitecturas bastante recientes que están demostrando ser prometedoras. Alternativamente, se podría investigar la combinación de arquitecturas de transformers junto a capas convolucionales, lo cual presenta desafíos adicionales como la necesidad de grandes conjuntos de datos y tiempo extenso de entrenamiento, pero ofrece potenciales beneficios en términos de rendimiento.

Finalmente, se podría implementar la teoría de evidencia de Dempster-Shafer para manejar la incertidumbre y la toma de decisiones cuando se utilizan múltiples modelos, donde la salida de cada modelo sería tratada como una fuente de información distinta.

## REFERENCES

- [1] D. Kermany, "Labeled optical coherence tomography (oct) and chest x-ray images for classification," 2018. [Online]. Available: <https://data.mendeley.com/datasets/rscbjbr9sj/2>
- [2] T. Rahman, A. Khandakar, and M. E. H. Chowdhury, "Tuberculosis (tb) chest x-ray database," 2020. [Online]. Available: <https://ieee-dataport.org/documents/tuberculosis-tb-chest-x-ray-database>
- [3] J. P. Cohen, P. Morrison, L. Dao, K. Roth, T. Duong, and M. Ghassem, "Covid-19 image data collection: Prospective predictions are the future," *Machine Learning for Biomedical Imaging*, vol. 1, no. December 2020, p. 1–38, Dec. 2020. [Online]. Available: <http://dx.doi.org/10.59275/j.melba.2020-48g7>
- [4] J. B. Thomas, M. Devvarma, and K. V. Shihabudheen, "Deep ensemble approaches for classification of covid-19 in chest x-ray images," in *2021 International Conference on Innovation and Intelligence for Informatics, Computing, and Technologies (3ICT)*. IEEE, Sep. 2021. [Online]. Available: <http://dx.doi.org/10.1109/3ICT53449.2021.9581389>
- [5] A. U. Ibrahim, M. Ozsoz, S. Serte, F. Al-Turjman, and P. S. Yakoi, "Pneumonia classification using deep learning from chest x-ray images during covid-19," *Cognitive Computation*, Jan. 2021. [Online]. Available: <http://dx.doi.org/10.1007/s12559-020-09787-5>
- [6] S. N. Ashraf, M. A. Mamun, H. M. Abdullah, and M. G. R. Alam, "Synthensembles: A fusion of cnn, vision transformer, and hybrid models for multi-label chest x-ray classification," in *2023 26th International Conference on Computer and Information Technology (ICCIT)*. IEEE, Dec. 2023. [Online]. Available: <http://dx.doi.org/10.1109/ICCIT60459.2023.10441433>
- [7] P. Saha and S. Neogy, "Concat\_cnn: A model to detect covid-19 from chest x-ray images with deep learning," *SN Computer Science*, vol. 3, no. 305, 2022. [Online]. Available: <https://doi.org/10.1007/s42979-022-01182-1>
- [8] A. D. Bodner, A. S. Tepsich, J. N. Spolski, and S. Pourteau, "Convolutional kolmogorov-arnold networks," 2024. [Online]. Available: <https://arxiv.org/abs/2406.13155>